MINISTÉRIO DA EDUCAÇÃO
INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DA BAHIA
CAMPUS VALENÇA

ENDREW CONCEIÇÃO, JOSÉ HENRIQUE CRUZ SOUZA, KEILA GOTARDO DOS SANTOS, MARIA IZABEL CORTEZ NUNES

DETECÇÃO DE LETRAS EM LIBRAS UTILIZANDO PONTOS DE REFERÊNCIA DE MÃOS

Valença-BA
2025

ENDREW CONCEIÇÃO, JOSÉ HENRIQUE CRUZ SOUZA, KEILA GOTARDO DOS SANTOS, MARIA IZABEL CORTEZ NUNES

DETECÇÃO DE LETRAS EM LIBRAS UTILIZANDO PONTOS DE REFERÊNCIA DE MÃOS

Trabalho de Conclusão de Curso do Curso Integrado de Informática, do Instituto Federal de Educação, Ciência e Tecnologia da Bahia, como requisito parcial para a obtenção do título de Técnico em Informática.

Orientador: Prof. Me. Rodolfo Costa Cezar da Silva

Valença-BA
2025

ENDREW CONCEIÇÃO, JOSÉ HENRIQUE CRUZ SOUZA, KEILA GOTARDO DOS SANTOS, MARIA IZABEL CORTEZ NUNES

DETECÇÃO DE LETRAS EM LIBRAS UTILIZANDO PONTOS DE REFERÊNCIA DE MÃOS

A banca examinadora, abaixo listada, **aprova** o Trabalho de Conclusão de Curso "DETECÇÃO DE LETRAS EM LIBRAS UTILIZANDO PONTOS DE REFERÊNCIA DE MÃOS" elaborado por "ENDREW CONCEIÇÃO, JOSÉ HENRIQUE CRUZ SOUZA, KEILA GOTARDO DOS SANTOS, MARIA IZABEL CORTEZ NUNES" como requisito parcial para obtenção do grau de Técnico em Informática, pelo Instituto Federal de Educação, Ciência e Tecnologia da Bahia.

Resultado : _____ - **Nota :** _____

Valença-BA, 14/02/2025

Comissão Examinadora

Prof. Me. Rodolfo Costa Cezar da Silva
Instituto Federal de Educação, Ciência e Tecnologia da Bahia - Campus Valença
(Orientador)

Prof. Me. Benardo Peter Menezes Silva
IFBA - Campus Valença

Prof. Dr. Joel Eugênio Cordeiro Junior
IFBA - Campus Valença

DETECÇÃO DE LETRAS EM LIBRAS UTILIZANDO PONTOS DE REFERÊNCIA DE MÃOS

Resumo

O presente trabalho propõe o desenvolvimento de uma ferramenta de reconhecimento de sinais em Língua Brasileira de Sinais (Libras) para auxílio pedagógico em instituições de ensino, utilizando visão computacional e aprendizado de máquina. A pesquisa tem natureza aplicada, com foco na inclusão educacional de pessoas surdas, buscando reduzir barreiras na comunicação por meio da tecnologia. O sistema é desenvolvido em Python e emprega bibliotecas como OpenCV, MediaPipe, TensorFlow e Keras para capturar e interpretar gestos manuais, sem utilizar modelos pré-treinados. A metodologia envolve a criação de um modelo próprio, treinado a partir de um conjunto de dados original captado pela equipe com a orientação de especialistas em Libras. O projeto inclui também uma aplicação web acessível para demonstrar o reconhecimento dos gestos em tempo real. Os resultados incluem um modelo eficiente na classificação de sinais básicos da Libras com até 93% de acurácia, com baixo custo computacional, tornando a ferramenta viável para implementação em escolas e ambientes com baixos recursos. Além disso, a disponibilização da base de dados contribuirá para pesquisas futuras na área de acessibilidade e inteligência artificial aplicada à educação em Libras. Com isso, o trabalho busca promover inclusão social e fortalecer o uso de tecnologias assistivas no ensino de Libras, ampliando as oportunidades educacionais para a comunidade surda.

Palavras-chave: Libras. Reconhecimento de Gestos. Visão Computacional. Aprendizado de Máquina. Inclusão Educacional.

DETECTING ALPHABET LETTERS IN BRAZILIAN SIGN LANGUAGE USING HAND LANDMARKS

Abstract

This work proposes the development of a Brazilian Sign Language (Libras) sign recognition tool to assist in teaching in educational institutions, using computer vision and machine learning. The research is applied in nature, focusing on the educational inclusion of deaf people, seeking to reduce communication barriers through technology. The system is developed in Python and uses libraries such as OpenCV, MediaPipe, TensorFlow and Keras to capture and interpret hand gestures, without using pre-trained models. The methodology involves the creation of an in-house model, trained from an original dataset collected by the team with the guidance of Libras experts. The project also includes an accessible web application to demonstrate gesture recognition in real time. The expected results include an efficient model for classifying basic brazilian language signs with accuracy up to 93%, and low computational cost, making the tool viable for implementation in schools and low-resource environments. In addition, the availability of the database will contribute to future research in the area of accessibility and artificial intelligence applied to Libras education. With this, the work seeks to promote social inclusion and strengthen the use of assistive technologies in teaching Libras, expanding educational opportunities for the deaf community.

Keywords: Libras. Gesture Recognition. Computer Vision. Machine Learning.

Sumário

1 –Introdução **1**

2 –FUNDAMENTAÇÃO TEÓRICA **3**

3 –PROCEDIMENTOS METODOLÓGICOS **6**

3.1 Sistema Proposto 6

3.2 Métricas 7

3.2.1 Formas de Avaliação 8

3.2.2 Matriz de Confusão 9

3.2.3 Acurácia 10

3.2.4 *Loss* 10

3.3 Base de Dados 11

3.3.1 Landmarks 11

3.3.2 Coleta de Dados 11

4 –RESULTADOS **13**

5 –CONCLUSÃO **15**

5.1 Limitações e Trabalhos Futuros 15

Referências **17**

1 Introdução

A tecnologia desempenha um papel crucial na inclusão de pessoas surdas no Brasil, especialmente em um contexto onde a Língua Brasileira de Sinais (Libras) ainda é pouco dominada pela maioria da população ouvinte. Ferramentas tecnológicas, como sistemas de tradução automática de Libras para texto ou áudio, e softwares de reconhecimento de gestos, tornam a comunicação mais acessível e ampliam a autonomia dos surdos em interações cotidianas e profissionais. Esses sistemas são essenciais não apenas para facilitar a comunicação, mas também para garantir que pessoas surdas possam exercer seus direitos à igualdade de oportunidades e não sofram discriminação, conforme assegurado pelo Estatuto da Pessoa com Deficiência (Lei nº 13.146/2015).

No Brasil, cerca de 5% da população apresenta algum grau de deficiência auditiva, o que equivale a mais de 10 milhões de pessoas, das quais cerca de 2,7 milhões têm surdez profunda (IBGE, 2022). A Libras, reconhecida como a segunda língua oficial do país e considerada uma língua natural, é usada por aproximadamente 22,4% das pessoas com deficiência auditiva entre 5 e 40 anos. Contudo, a falta de domínio da Libras por grande parte da população ouvinte reforça as barreiras de comunicação, dificultando a inclusão plena dos surdos em diversas áreas da sociedade.

Esse cenário é ainda mais desafiador na educação, onde 61.594 alunos da educação básica possuem alguma deficiência auditiva. Apesar dos esforços para inclusão, o Ministério da Educação (MEC), apenas 7% da população brasileira com deficiência auditiva concluiu o ensino superior, evidenciando lacunas significativas no acesso à educação de qualidade para essas pessoas. A carência de intérpretes de Libras nas instituições de ensino é um dos principais fatores limitantes, tornando fundamental o uso de ferramentas automáticas e informatizadas para mitigar essas dificuldades.

Diversas tecnologias brasileiras têm sido desenvolvidas para auxiliar na educação de pessoas surdas, promovendo acessibilidade e inclusão. Ferramentas para tradução digital de texto e voz para a Libras e plataformas de tradução automática para dispositivos eletrônicos, têm sido amplamente utilizadas. Sistemas baseados em visão computacional e aprendizado de máquina também se destacam, permitindo a tradução de Libras para texto ou áudio em tempo real. Além disso, plataformas educacionais adaptadas, como videoaulas em Libras, aplicativos interativos e softwares com tradução automática integrada, possibilitam que estudantes surdos acompanhem conteúdos educacionais de forma mais independente. Essas tecnologias não apenas reduzem barreiras linguísticas, mas também ampliam as oportunidades de aprendizado, promovendo a inclusão social e educacional.

Em primeiro lugar, faz-se necessário destacar que apesar dos avanços em softwares

de tradução para a linguagem de sinais, a conversão de sinais para palavras permanece um campo escasso, com pouco desenvolvimento. Isso ocorre porque o processo exige não apenas a captura dos gestos, mas também sua interpretação precisa e a tradução em palavras, o que apresenta desafios técnicos significativamente maiores em comparação à tradução de palavras para sinais. É válido ressaltar que a grande maioria dos projetos voltados para a inclusão e para a acessibilidade de pessoas com deficiência auditiva são feitos para outras linguagens de sinais e não especificamente para Libras, ou seja, a coleção de dados disponíveis em Língua de Sinais Brasileira é escassa. Além disso, muitas técnicas necessitam de uma infraestrutura mais robusta e incompatível com a realidade brasileira, especialmente em escolas públicas.

Ademais, também é importante ressaltar como a busca para uma inclusão de pessoas com deficiência auditiva nas instituições de ensino foi uma fonte de motivação, juntamente com a ideia de fornecer uma ferramenta para ajudar na formação educacional dessas pessoas. Diante dessas lacunas, este trabalho propõe a criação de um sistema web acessível e de baixo custo para o reconhecimento básico de letras da Língua Brasileira de Sinais (Libras), voltado especialmente para aplicação em instituições de ensino. O sistema visa não apenas promover a inclusão social e educacional, mas também contribuir com a disponibilização de bases de dados próprias, captadas pela equipe com orientações de profissionais da área, com pontos de referência (*landmarks*) e vídeos, servindo como ponto de partida para futuras pesquisas e aplicações.

A abordagem combina tecnologias acessíveis, que podem ser implementadas com pouca infraestrutura, com orientações de profissionais especializados, garantindo precisão e adequação ao contexto educacional. Assim, o projeto almeja oferecer uma ferramenta prática para auxiliar na didática pedagógica, ampliando as oportunidades de comunicação e aprendizado de pessoas surdas em ambientes de ensino, promovendo uma sociedade mais inclusiva e equitativa.

O trabalho é organizado da seguinte forma: No Capítulo 2 é apresentado uma breve revisão da literatura. No Capítulo 3 são apresentados os métodos e metodologias utilizadas no desenvolvimento do trabalho. No Capítulo 4 são apresentados os resultados obtidos, seguidos por uma conclusão e apresentação de trabalhos futuros no Capítulo 5.

2 FUNDAMENTAÇÃO TEÓRICA

Os autores em (CAIAFA et al., 2020) propõe utilizar arquiteturas neurais profundas para reconhecimento de sinais em Libras. Os autores utilizam duas bases de dados conhecidas e propõem analisá-las utilizando acurácia. Os autores utilizam as seguintes redes neurais para reconhecimento de sinais em Libras : LeNet , VGG16 , VGG19 , InceptionV3 e ResNet50. Os autores utilizaram uma metodologia de *10-fold-cross validation* e as acurácias nos *folds* de teste chegam até 99,13%.

O artigo descrito em (ROSSIT et al., 2022) descreve um sistema de tradução de Libras para áudio, visando a inclusão social de pessoas surdas. O sistema combina aprendizado de máquina e visão computacional, capturando sinais em Libras por *webcam* e processando-os em tempo real com a arquitetura MobileNetV2, implementada em TensorFlow Lite. O processamento ocorre em um Raspberry Pi, que converte sinais em texto e áudio com Pyttsx3. Treinado com 800 imagens, o sistema atingiu precisão entre 81% e 99%, mostrando-se eficaz em diferentes condições de iluminação. Em contraste, o modelo proposto nesse trabalho usa dados exclusivos, sem redes pré-treinadas, permitindo maior adaptação para o ensino de Libras em ambiente educacional.

O trabalho desenvolvido em (ALBINO, 2023) descreve uma plataforma web que traduz Libras para texto em tempo real, facilitando a comunicação entre surdos e ouvintes. Usando o algoritmo Dynamic Time Warping (DTW) com MediaPipe para captar movimentos das mãos, o sistema utilizou bases de dados como LSA64 (RONCHETTI et al., 2023), MINDS (REZENDE, 2021), HOW2SIGN (DUARTE et al., 2021) e WSASL (LI et al., 2020), com uma divisão 50/50 para treinamento e teste, onde metade das instâncias são separadas para treino e e a outra metade para teste. O modelo obteve até 97,04% de acurácia, destacando-se na base de dados HOW2SIGN, enquanto a base WSASL apresentou menor acurácia (88,92%) devido à baixa qualidade dos vídeos. Diferente do projeto analisado, este trabalho foca em dados originais captados com o auxílio de especialistas em Libras e em na captação do rosto e pose do usuário também, visando mais a aplicação pedagógica em instituições de ensino. Os autores utilizam bases de dados disponíveis e não dados originais, e utilizam apenas uma forma de teste, o que pode levar a resultados enviesados.

Em (ALBINO, 2023), é apresentado um sistema de baixo custo que usa uma luva equipada com sensores IMU (acelerômetros e giroscópios) para traduzir o alfabeto manual de Libras para português em tempo real. Dados coletados pela luva são enviados via *bluetooth* para um *smartphone*, onde redes neurais classificam os sinais. A técnica RBFN obteve 99,84% de acurácia em tempo real, demonstrando alta precisão e resposta

rápida. O presente projeto, ao contrário, utiliza apenas a *webcam* de dispositivos comuns, eliminando a necessidade de equipamentos adicionais, proporcionando uma solução prática e acessível para o ensino de Libras, e que pode ser aplicado em diferentes ambientes com pouco recurso.

O artigo descrito em (SILVA, 2023) desenvolve um sistema para traduzir Libras em português com redes neurais LSTM e visão computacional, empregando MediaPipe[1] para identificar pontos de referência nas mãos. O estudo também aplica técnicas de aumento de dados, como espelhamento e ajuste de brilho, usando vídeos de cinco participantes que sinalizam expressões como "Eu te amo". Com 70% dos dados para treinamento, o conjunto que combinou todas as técnicas de aumento atingiu 100% de precisão. Neste trabalho, foi priorizado dados personalizados captados com o auxílio de especialistas em Libras, desenvolvimento e aplicação de baixo custo.

O artigo descrito em (MONTEIRO et al., 2016) apresenta um sistema de reconhecimento automático de sinais em Libras com três extratores de características: Forma, Área Proporcional e Posição Relativa. O Extrator de Forma calcula o centro de gravidade e raios até a borda da imagem, reduzindo dimensionalidade; o Extrator de Área Proporcional mede a área relativa de segmentos da mão; e o Extrator de Posição Relativa calcula a posição desses segmentos. A precisão atingiu 87,67% com extratores específicos para Libras. A técnica de subtração de quadros foi usada para capturar movimentos, já neste trabalho, foca-se na interpretação de configuração de movimentos, usando MediaPipe para obter *landmarks* das mãos e pose, bem como mecanismos para uma resposta em tempo real. Além disso, utilizamos uma coleção de dados própria e avaliamos o conjunto de teste sob duas óticas, garantindo que o modelo não fosse avaliado de forma enviesada baseada apenas em uma coleção de teste.

O artigo descrito em (CLAUDINO et al., 2022) relata o desenvolvimento de uma CNN para reconhecer 20 sinais de Libras com o dataset MINDS-Libras (REZENDE, 2021), testando técnicas de pré-processamento como Canny, Sobel e binarização adaptativa. Dados originais normalizados resultaram na maior precisão (90,08%) e menos ruído nas curvas de *loss*, enquanto a binarização adaptativa indicou *underfitting*. Embora explore pré-processamento para otimizar a classificação de sinais, o presente trabalho enfatiza a interpretação direta de movimentos contínuos, necessitando pré-processamento extensivo para manter a simplicidade e a aplicabilidade em tempo real.

O artigo (CAIAFA et al., 2020) explora o uso de redes neurais profundas para o reconhecimento de gestos estáticos na Língua Brasileira de Sinais (LIBRAS), aplicando técnicas de aprendizado profundo para alcançar alta acurácia na classificação de sinais. A pesquisa utiliza as bases de dados públicas e modelos como LeNet, VGG16, VGG19, InceptionV3 e ResNet50, avaliados por validação cruzada. As redes atingiram acurácia de

[1] https://pypi.org/project/mediapipe/

até 99,17% com VGG19 e 99,13% com InceptionV3 nas bases respectivas. Diferente do estudo mencionado, este projeto utiliza o *framework* MediaPipe para reconhecimento de gestos em LIBRAS e um modelo próprio treinado com sinais em Linguagem Brasileira de Sinais, adotando uma abordagem alternativa para detecção de gestos em tempo real e viável para aplicações em dispositivos de baixo custo, o que permite uma implementação eficiente em ambientes variados.

O artigo (BARROS et al., 2014) propõe um sistema para o reconhecimento de gestos da Língua Brasileira de Sinais (LIBRAS) utilizando câmeras convencionais e algoritmos de visão computacional, visando facilitar a comunicação entre surdos e ouvintes. A metodologia emprega uma base de dados composta por imagens dos números 0, 1, 2, 3, 4, 5, 7 e 8, capturadas de oito indivíduos, aplicando técnicas de segmentação de pele para isolar mãos e braços, e classificação dos gestos com o uso de uma máquina de vetores de suporte (SVM). Nos testes, alcançou-se uma acurácia de 83% com 40% das imagens para treinamento e 60% para teste, enquanto com 80% para treinamento e 20% para teste, a acurácia chegou a 87%. De maneira contrária, o presente trabalho se concentra no reconhecimento de gestos em LIBRAS utilizando o *framework* MediaPipe, que permite a detecção em tempo real com eficiência e precisão. A abordagem com MediaPipe possibilita uma implementação em dispositivos de baixo custo e em ambientes variados, favorecendo a comunicação acessível em LIBRAS e ampliando as oportunidades para interação entre surdos e ouvintes em contextos diversos, tornando o projeto mais aplicável.

O trabalho desenvolvido em(BERTIPAGLIA; JUNIOR, 2024) propõe um sistema que traduz sinais de Libras em fala audível em tempo real, utilizando redes neurais convolucionais (CNN) para facilitar a comunicação entre surdos e ouvintes. Com um conjunto de dados representativo de Libras, que abrange variações regionais, o projeto emprega técnicas de pré-processamento e arquiteturas de CNN, além de redes 3D-CNN e RNN, para capturar informações temporais e espaciais. Focado em métricas de acurácia e F1-score, o sistema visa alta precisão e usabilidade prática em contextos sociais e educacionais, promovendo inclusão e acessibilidade para a comunidade surda. Em contraste, o presente trabalho proposto adota uma abordagem mais direta com MediaPipe para detecção dos pontos corporais e OpenCV para captação de imagens, sem utilizar modelos complexos de CNN. Este projeto também conta com um modelo treinado inteiramente em dados originais coletados por nossa equipe, evitando a dependência de dados pré-existentes e oferecendo precisão direcionada ao ensino de Libras.

3 PROCEDIMENTOS METODOLÓGICOS

3.1 Sistema Proposto

O sistema desenvolvido no presente projeto tem como objetivo principal reconhecer sinais básicos da Língua Brasileira de Sinais (Libras), com foco em determinadas letras do alfabeto. A seleção de um conjunto reduzido de letras foi uma escolha estratégica para facilitar a análise e testar o funcionamento do sistema de maneira controlada. Nesse contexto, foram utilizados representações de letras em LIBRAS cujo sinais são estáticos, ou seja, cujo gestos não envolvem movimentos. São essas representações de letras : a, b, c, d, e, f, g, i, l, m, n, o, p, q, r, s, t, u, v, y, w.

A base tecnológica do projeto está centrada na utilização de visão computacional por meio do *framework* MediaPipe, que é responsável pela captura e rastreamento dos movimentos das mãos. Essa tecnologia permite identificar as posições das articulações dos dedos e das palmas, gerando dados que são utilizados tanto para o treinamento do modelo de reconhecimento quanto para o próprio reconhecimento dos gestos. Com o processamento dessas informações, é possível traduzi-las em texto, viabilizando a interatividade entre ser humano e máquina.

O projeto foi desenvolvido para ser acessível e de baixo custo. Nesse sentido, são utilizadas câmeras convencionais, como as de notebooks ou *webcams*, o que torna o sistema mais viável para escolas e instituições que dispõem de recursos financeiros limitados.

Inicialmente, foram capturadas imagens para o treinamento do modelo utilizando a biblioteca OpenCV. Posteriormente, foi criado um arquivo de pacote de modelo do MediaPipe, um modelo de treinamento ajustado para tarefas específicas, como o reconhecimento dos gestos definidos. Esse modelo foi treinado utilizando dados coletados pela equipe em parceria com uma profissional de Libras, para garantir maior precisão e confiabilidade nos resultados.

O treinamento do modelo seguiu etapas bem definidas: primeiramente, as imagens coletadas foram rotuladas em pastas, associando cada uma delas ao gesto correspondente. Em seguida, essas imagens passaram por um processo de normalização e conversão - matrizes de coordenadas dos *landmarks* - para serem compatíveis com o formato exigido pelo MediaPipe. Durante o treinamento, o modelo ajustou seus parâmetros internos para diferenciar com eficiência os gestos com base nos dados fornecidos. O resultado é a criação de um arquivo de extensão ".task", que é exportado no formato adequado para integração com a aplicação web.

O sistema final é disponibilizado por meio de uma aplicação web, acessível a qual-

quer usuário com um navegador de internet. A aplicação no navegador pode ser dividida em dois componentes do sistema: *frontend e backend*.

No *backend*, desenvolvido em Python, foram realizadas diversas etapas fundamentais para o funcionamento do sistema. A comunicação entre o *frontend* e o *backend* é realizada através de APIs desenvolvidas no *framework* Django. O Django gerencia as rotas e o armazenamento de dados, facilitando a troca de informações entre os componentes do sistema. Quando o usuário realiza um gesto, a imagem capturada pela câmera é enviada ao servidor, onde o modelo treinado processa e classifica o gesto. O resultado dessa classificação é então enviado de volta para o *frontend*, onde o texto correspondente ao gesto é exibido de forma dinâmica na interface do usuário.

No *frontend*, foram utilizadas as linguagens HTML e CSS para estruturar e estilizar as páginas web, garantindo uma interface amigável e acessível. Além disso, o JavaScript foi empregado para implementar funcionalidades interativas, como a captura de imagens em tempo real e a exibição imediata dos resultados do reconhecimento, como pode ser visto na Figura (Figura 1). Além disso, o sistema permite que, utilizando o alfabeto, forme-se palavras completas. O uso dessas tecnologias permitiu criar uma aplicação responsiva e eficiente, proporcionando uma experiência intuitiva aos usuários (Figura 1b)

A versão final da aplicação inclui uma página de apresentação que expõe a proposta do sistema, suas funcionalidades e os principais dados utilizados na pesquisa para o desenvolvimento do projeto. Inicialmente, foi implementado um módulo que permite a formação de palavras por meio de gestos captados pela *webcam* do dispositivo, incentivando o uso lógico da linguagem de sinais.

(a) Layout da página inicial do sistema WEB

(b) Funcionalidade de criação de palavras em funcionamento.

Figura 1 – Funcionalidades do Sistema WEB criado.

3.2 Métricas

Para avaliar o desempenho do sistema de reconhecimento de sinais em LIBRAS, será utilizado a acurácia como métrica principal. Essa métrica foi escolhida por fornecer uma análise abrangente do desempenho do modelo na identificação correta dos sinais.

Além disso a métrica é extremamente popular e utilizada nos modelos de detecção de gestos, tornando possível, assim, a comparação com outros modelos de detecção de gestos. A acurácia, apesar de ser uma métrica amplamente utilizada para avaliar o desempenho de modelos de classificação em geral, não deve ser utilizada em coleções de dados onde existe um desbalanceamento de número de instâncias das classes. O motivo é que o resultado de acurácia em coleções de dados desbalanceadas pode ser mal interpretado.

Imagine uma coleção de dados binária desbalanceada, onde a classe minoritária (classe A) tem 100 exemplos e a classe majoritária (classe B) tem 900 exemplos. Agora imagine um modelo de classificação, que independente da classe da instância que ele receber como entrada, classifica a instância como sendo da classe B. O modelo de classificação descrito terá uma acurácia de 90%, simplesmente por ter repetido a mesma classificação. Os modelos de aprendizado de máquina são construídos na premissa de serem treinados e testados em coleções de dados balanceadas, e quando esse não é o caso, é preciso considerar técnicas para diminuir ou acabar com o desbalanceamento de classes, ou quando não for possível, utilizar métricas que levem em consideração mais do que apenas os acertos gerais (como a acurácia), e sim métricas que analisem os erros e acertos por classe.

Entretanto, tendo em vista que a coleção de dados utilizada nesse trabalho não apresenta um desbalanceamento de classes substancial, ou seja, todas as classes (gestos) tem, em média, a mesma quantidade de instâncias, pode-se utilizar a acurácia como métrica. Além disso, também é reportado o *loss*, que representa a função de perda do modelo durante o treinamento e a validação. O *loss* mede a diferença entre as previsões do modelo e os valores reais esperados, sendo um indicador essencial para avaliar a capacidade de aprendizado da rede neural. Quanto menor o *loss*, melhor é o ajuste do modelo aos dados.

3.2.1 Formas de Avaliação

Para garantir uma avaliação mais exata, foram adotadas duas formas de avaliação: a **divisão 80/20** e a **validação cruzada de cinco partes (*5-fold cross-validation*)**.

Na abordagem 80/20, 80% dos dados foram utilizados para o treinamento e 20% para a validação, permitindo medir o desempenho do modelo em um conjunto de dados que não foi usado para o treinamento. Nesse caso, a métrica é calculada utilizando apenas uma parcela (20%) do conjunto de dados.

Já na validação cruzada de cinco partes, o conjunto de dados foi dividido em cinco partes (*folds*), que, em cada iteração, quatro partes foram usadas para treinamento e uma para validação, garantindo que todas as instâncias fossem usadas tanto para treino quanto para teste em algum momento, dessa forma, é possível reduzir a dependência da divisão inicial e fixa dos dados, fornecendo uma métrica mais confiável sobre a performance do

modelo. O processo de iteração do treinamento nesse método pode ser ilustrado como na Figura 2, onde em cada iteração o modelo é treinado com 4/5 do conjunto de dados. Após o treinamento é gerado um modelo de inferência que é testado na parcela restante (1/5) do conjunto de dados que não foi utilizada no treinamento, com isso, são extraídas as métricas. Após a quinta iteração, nesse caso, é calculado uma média aritmética das cinco métricas extraídas. Esse valor obtido é o valor reportado nos resultados obtidos.

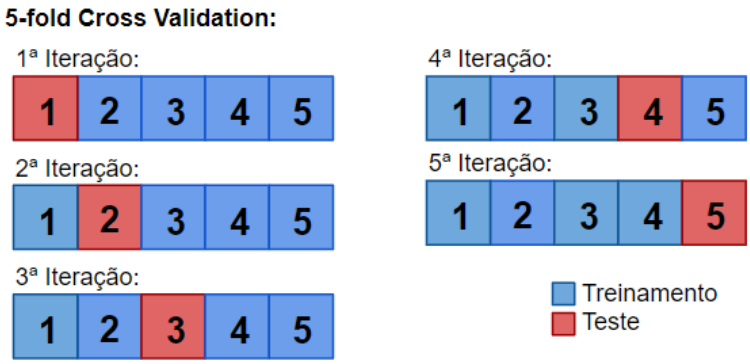

Figura 2 – Processo de iteração da validação cruzada

Os resultados obtidos para ambas as abordagens são discutidos no Capítulo 4, onde são analisadas as métricas de acurácia e *loss* para ambas as estratégias de avaliação.

3.2.2 Matriz de Confusão

Antes do conceito das métricas, é necessário entender como são classificadas a previsões analisadas pelas métricas por meio da matriz de confusão. A matriz de confusão é uma ferramenta essencial para avaliar o desempenho de modelos de classificação. Ela organiza os resultados das previsões do modelo em quatro categorias principais: verdadeiros positivos (TP), verdadeiros negativos (TN), falsos positivos (FP) e falsos negativos (FN). Cada uma dessas categorias reflete o tipo de acerto ou erro feito pelo modelo, permitindo uma análise detalhada de seu comportamento.

- **TP** ***(True Positives)***: Previsões corretas de instâncias positivas.
- **TN** ***(True Negatives)***: Previsões corretas de instâncias negativas.
- **FP** ***(False Positives)***: Previsões incorretas de instâncias negativas
- **FN** ***(False Negatives)***: Previsões incorretas de instâncias positivas

A matriz é organizada da seguinte forma:

	Predição Positiva	Predição Negativa
Classe Positiva	TP	FN
Classe Negativa	FP	TN

Com essa classificação, é possível utilizar várias métricas de avaliação, como a acurácia e o *loss* usadas nesse projeto.

3.2.3 Acurácia

A Acurácia é uma métrica que mede a proporção de previsões corretas feitas pelo modelo em relação ao total de previsões. Ela é amplamente utilizada em problemas de classificação quando o conjunto de dados é balanceado, pois dessa forma não apresenta desproporções das variáveis de previsão. A acurácia é descrita através da fórmula baixo:

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN}$$

3.2.4 *Loss*

Utilizando a acurácia como métrica de análise principal, a função de perda (o ***loss***) é apresentada como valor complementar à acurácia na perspectiva de uma interpretação probabilística.

Na teoria das probabilidades, é possível definir o espaço amostral Ω como o conjunto de todas as possibilidades possível realizadas pelo modelo. Nesse contexto, define-se dois eventos:

- Evento A: previsões corretas (acurácia)
- Evento B: previsões incorretas (*loss*)

Pela regra da probabilidade:

$$P(A) + P(B) = P(\Omega) = 1$$

Dessa maneira, é visível que a porcentagem de previsões incorretas é complementar à porcentagem de previsões corretas pelo sistema. Também pode-se calcular o *loss* do modelo pelos elementos da matriz de confusão através da seguinte fórmula:

$$Loss = \frac{FP + FN}{TP + TN + FP + FN}$$

3.3 Base de Dados

3.3.1 Landmarks

O modelo de reconhecimento de gestos de Libras deste projeto é baseado na identificação de pontos de referência na mão, conhecidos como ***landmarks***. Esses *landmarks* representam coordenadas específicas da estrutura da mão no espaço tridimensional, permitindo que o modelo analise a posição dos dedos e da palma em diferentes gestos, permitindo o treinamento e identificação de diferentes gestos.

O MediaPipe Hands, *framework* utilizado no projeto, consegue detectar 21 *landmarks* em cada mão, distribuídos entre os dedos e a palma como na Figura 3. Cada um desses pontos é identificado por um número e possui coordenadas (x, y, z).

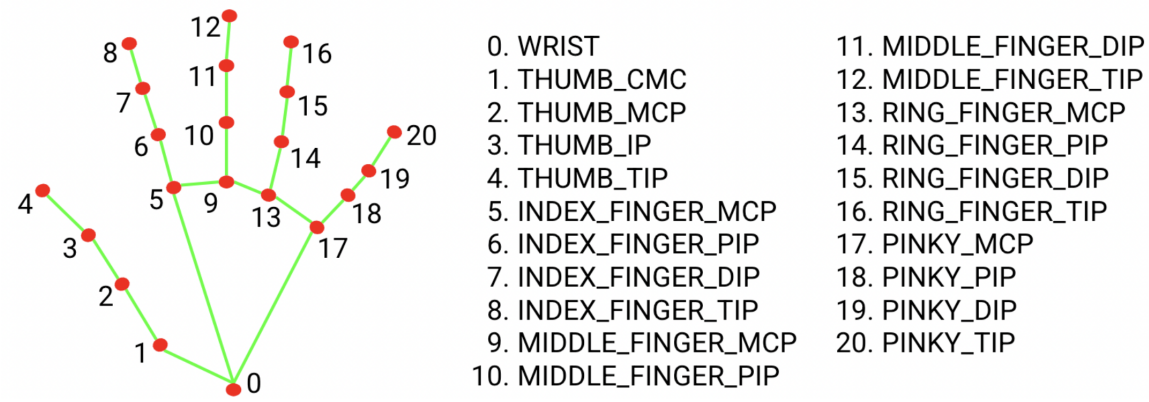

Figura 3 – Localização dos *Landmarks* da mão.

No treinamento do modelo deste trabalho, os *landmarks* são usados como entradas para a rede neural especializada do MediaPipe. A partir dos dados coletados, o sistema aprende a diferenciar os gestos com base na posição e movimentação relativa dos *landmarks*, como pode ser visto na Figura 4. Os mesmos *landmarks* usados como informações de entrada para o treinamento do modelo, são os mesmos usados na aplicação web para a interação do usuário com o sistema de reconhecimento de gestos da ferramenta, possibilitando a identificação em tempo real dos gestos feitos pelos usuários.

3.3.2 Coleta de Dados

A base de dados consiste em imagens que foram capturadas por uma *webcam*, promovendo o uso equipamentos de baixo custo para o treinamento do modelo que possui uma base de dados própria. Conforme exposto, foram utilizados representações de letras em Libras cujo gestos são estáticos, ou seja, cujo gestos não envolvem movimentos. São essas representações de letras : a, b, c, d, e, f, g, h, i, l, m, n, o, p, q, r, s, t, u, v, y, w. Além desses gestos, o *framework* utilizado exige que se utilize uma classe extra (*None*), para

(a) *Landmarks* com palma aberta (b) *Landmarks* com palma fechada

Figura 4 – Exemplos de *Landmarks* em diferentes configurações.

que o modelo classifique o gesto caso não consiga identificar ou definir o gesto e inseri-lo em qualquer outra classe.

A base de dados utilizada no projeto foi desenvolvida integralmente por nossa equipe sob a orientação de uma especialista em Libras, com o objetivo de atender as necessidades específicas do modelo de reconhecimento. O processo de criação envolveu a captura de gestos em vídeos ao vivo, que foram posteriormente divididos em *frames* individuais (imagens). Esse método permitiu gerar um conjunto considerável de dados para o treinamento e validação do sistema.

Para garantir diversidade e promover a generalização do modelo, a coleta de dados foi realizada com cinco participantes. Cada gesto foi realizado por diferentes indivíduos, sob variados ângulos em relação à câmera, e em diferentes posições dentro do campo de visão da mesma. Essa abordagem simulou cenários reais de uso, onde o sistema precisa lidar com situações dinâmicas e variadas.

A captura das imagens foi feita utilizando *webcam* convencional (Webcam Multilaser Modelo GLT-0001-WB), promovendo acessibilidade e facilidade de execução. Em média, foram extraídas cerca de 650 imagens por gesto, totalizando mais de 15000 de imagens que compõem a base de dados. Informações detalhadas sobre a coleção de dados, e quantidade de *frames* por sinal pode ser ista na Tabela 1.

símbolo	**a**	**b**	**c**	**d**	**e**	**f**	**g**	**h**	**i**	**l**	**m**	**n**	**o**	**p**	**q**	**r**	**s**	**t**	**u**	**v**	**y**	**w**	**Média**
# frames	840	661	751	924	655	677	645	647	647	643	616	645	800	553	681	654	803	760	911	851	673	715	**721,19**

Tabela 1 – Informações sobre coleção de dados. A primeira linha descreve o sinal em Libras, e a segunda linha descreve a quantidade de *frames* por sinal. A última coluna descreve a média de frames por gesto.

4 RESULTADOS

Os resultados foram analisados a partir das duas formas de análises citadas anteriormente: **divisão 80/20** e ***5-fold cross-validation***. A métrica de acurácia e a função de perda (*loss*) foram as medidas utilizadas para avaliar o desempenho do modelo. A tabela anexada mostra que o modelo atingiu 93,94% de acurácia na divisão 80/20 e 86,86% na validação cruzada 5-fold, com valores de loss de 0,13 e 0,21, respectivamente.

Método de teste	**Acurácia**	**Loss**
80/20	0.9394754767417908	0.1319136619567871
5-fold cross validation	0.8688634634017944	0.20921830832958221

Tabela 2 – Resultados do modelo utilizando duas formas de teste

A diferença nos valores de acurácia pode ser explicada por alguns fatores. No método *5-fold cross-validation*, o modelo é treinado e testado em diferentes subconjuntos dos dados, revelando possíveis fragilidades que podem não aparecer na divisão 80/20, desda forma, a validação cruzada testa o modelo em cenários mais variados, enquanto a divisão 80/20 pode, por sorte, ter uma distribuição mais favorável dos dados, principalmente de um conjunto de dados desbalanceados.

Outro processo que pode influenciar essa a distinção dos resultado é o *overfitting*, um problema existente quando o modelo é treinado com padrões excessivamente específicos, possuindo um má generalização para o reconhecimento dos padrões em casos de dados reais, por exemplo. Nesse contexto, a validação cruzada reduz o *overfitting*, pois distribui melhor os dados de treino e teste, refletindo de forma mais realista o desempenho do modelo.

Além das métricas quantitativas, observações qualitativas foram feitas sobre o reconhecimento dos sinais. Um dos principais desafios identificados foi a distinção entre gestos similares com significados distintos, como por exemplos os gestos para as letras "S"e "A", pois ambos possuem uma configuração de *landmarks* semelhantes, ou seja, são gestos similares (Vide Figura 5), com os punhos cerrados e os dedos em posição relativamente similar. Dependendo do ângulo da câmera, um "A"pode parecer um "S"e vice-versa. Pequenas variações na forma como cada pessoa executa o gesto também impactam a precisão do modelo. Para resolver esse problema, futuras versões do modelo podem incluir mais variações nos exemplos de treinamento com diferentes ângulos e iluminações, entretanto o problema em reconhecimento de gestos muito similares pode ser um problema de posicionamento da mão e/ou ângulo de captura ao realizar o gesto.

Outro ponto observado foi a diferença no reconhecimento dos gestos dependendo da mão utilizada. Alguns sinais eram mais facilmente identificados quando feitos com uma

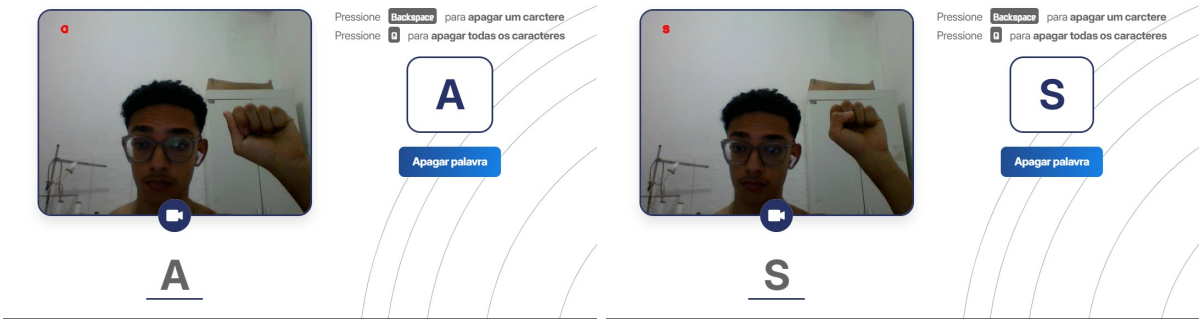

(a) Gesto em Libras para a letra "A" (b) Gesto em Libras para a letra "S"

Figura 5 – Exemplos de gestos similares com significados distintos.

mão específica, o que pode estar relacionado a variações na posição dos dedos entre a mão dominante e a não dominante. Além disso, se os dados de treino possuírem uma proporção maior para uma das mãos, o modelo pode apresentar dificuldades em reconhecer gestos feitos com a outra. Para reduzir esse conflito, é possível balancear melhor os dados coletados utilizando técnicas para aumentar a quantidade de *frames*, e ao mesmo tempo incluir gestos simulados com mãos diferentes, como por exemplo a técnica ***mirror augmentation***, que utiliza reflexão das imagens com o objetivo de aumentar a diversidade do treinamento.

Os resultados obtidos mostram que o modelo já apresenta uma taxa de acerto significativa, mas ainda há espaço para aprimoramentos em questões específicas.

5 CONCLUSÃO

O desenvolvimento deste trabalho representou um passo importante na aplicação de tecnologias computacionais para o reconhecimento de sinais em Libras, com foco na inclusão social e educacional de pessoas surdas.

Como destaque deste projeto, a acurácia obtida demonstra que o modelo desenvolvido é capaz de reconhecer sinais com um bom nível de precisão, especialmente considerando os desafios inerentes à variação de gestos e à similaridade entre alguns sinais. Outro diferencial do projeto foi a criação de uma coleção de dados original, com vídeos, imagens e landmarks, o que representa uma contribuição relevante para futuros estudos e aplicações na área. É importante ressaltar o desenvolvimento de uma solução de baixo custo utilizando ferramentas acessíveis, o que reforça a possibilidade da utilização de aplicações tecnológicas voltadas para a acessibilidade mesmo em contextos com restrições orçamentárias, como em instituições de ensino.

5.1 Limitações e Trabalhos Futuros

Ao longo do desenvolvimento deste projeto, foram enfrentados desafios que impactaram diretamente as decisões tomadas, limitando o alcance de algumas abordagens desejadas. Essas limitações, contudo, são também identificadas como oportunidades para futuras melhorias.

Uma das principais limitações consiste na coleção de dados reduzida, o que restringiu a capacidade do modelo de generalizar adequadamente para diferentes cenários. Essa limitação compromete a identificação de variações importantes nos sinais em Libras, como ângulo ou estilo de execução entre usuários. Para superar essa barreira em trabalhos futuros, é fundamental expandir o conjunto de dados, garantindo maior diversidade e representatividade, o que resultará em modelos mais robustos e precisos. Uma abordagem promissora para aumentar a base de dados é a utilização de técnicas de *data augmentation*, que permitem gerar variações nas imagens captadas, replicando-as com modificações como rotação, espelhamento e alteração de luminosidade, sem comprometer a classificação semântica.

Outro obstáculo significativo envolve a infraestrutura computacional limitada, especialmente pela ausência de uma GPU robusta. Essa restrição impede na utilização de modelos de treinamento mais avançados, como camadas de redes neurais CNNs e LSTM, que demandam maior poder computacional. O uso de equipamentos de baixo custo foi importante para a viabilidade do projeto dentro do contexto proposto, mas, para trabalhos

futuros, investimentos em infraestrutura poderiam permitir a implementação de soluções mais sofisticadas e eficientes.

Além disso, a escolha de uma abordagem baseada em *landmarks* simplificados foi uma decisão motivada por limitações de tempo e recursos. Embora eficiente e alinhada às necessidades do cronograma, essa simplificação resultou na perda de detalhes importantes, como expressões faciais e movimentos dinâmicos. No futuro, recomenda-se explorar representações mais completas, que integrem maior riqueza de informações para melhor capturar a complexidade dos sinais em Libras.

Essas limitações destacam áreas para avanço e aprimoramento em pesquisas futuras. Expandir a base de dados, investir em infraestrutura tecnológica e adotar técnicas mais detalhadas são caminhos que podem fortalecer o impacto de iniciativas como esta. é visível que essas barreiras, embora desafiadoras, são também oportunidades para ampliar a relevância e aplicabilidade do trabalho, contribuindo para a inclusão social e para o avanço na área de tecnologia assistiva.

Referências

ALBINO, M. d. S. Reconhecimento de linguagem de sinais utilizando o algoritmo dynamic time warping para auxiliar surdos. 2023.

BARROS, R.; PONTES, A. V.; ALMEIDA, J. Reconhecimento de linguagem de sinais: aplicação em libras. **V Jornada de Informática do Maranhão on Proceedings, São Luís, Maranhão**, 2014.

BERTIPAGLIA, A. F.; JUNIOR, G. F.

Reconhecimento de sinais da Libras por Visão Computacional — Universidade Estadual de Londrina, 2024.

CAIAFA, E. G.; FONSECA, F. F.; LIMA, A. A.; ARAUJO, G. M.; SILVA, E. A. da. Aprendizado profundo no reconhecimento de sinais estáticos de libras. In: **Proc. 38th Simpósio Brasileiro de Telecomunicações e Processamento de Sinais**. [S.l.: s.n.], 2020. p. 1–5.

CLAUDINO, M. M. et al. Reconhecimento de libras em frames estáticos de vídeos utilizando cnn e técnicas de pré-processamento de imagens. Universidade Federal de Campina Grande, 2022.

DUARTE, A.; PALASKAR, S.; VENTURA, L.; GHADIYARAM, D.; DEHAAN, K.; METZE, F.; TORRES, J.; NIETO, X. Giro-i. How2sign: a large-scale multimodal dataset for continuous american sign language. In: **Proceedings of the IEEE/CVF conference on computer vision and pattern recognition**. [S.l.: s.n.], 2021. p. 2735–2744.

IBGE. **Censo Demográfico 2022**. Rio de Janeiro: Instituto Brasileiro de Geografia e Estatística, 2022.

LI, D.; RODRIGUEZ, C.; YU, X.; LI, H. Word-level deep sign language recognition from video: A new large-scale dataset and methods comparison. In: **Proceedings of the IEEE/CVF winter conference on applications of computer vision**. [S.l.: s.n.], 2020. p. 1459–1469.

MONTEIRO, C. H. d. A.; PECORARO, L. F. I.; LACERDA, A. T.; CORBO, A. R.; ARAUJO, G. M. Um sistema de baixo custo para reconhecimento de gestos em libras utilizando visão computacional. In: **XXXIV Simpósio Brasileiro de Telecomunicações**. [S.l.: s.n.], 2016. p. 349–352.

REZENDE, T. M. Reconhecimento automático de sinais da libras: desenvolvimento da base de dados minds-libras e modelos de redes convolucionais. 2021.

RONCHETTI, F.; QUIROGA, F. M.; ESTREBOU, C.; LANZARINI, L.; ROSETE, A. Lsa64: an argentinian sign language dataset. **arXiv preprint arXiv:2310.17429**, 2023.

ROSSIT, B. N.; OLIVEIRA, E. dos S.; VASCONCELLOS, J. G. M. Talkbox: tradução de libras com machine learning. 2022.

SILVA, K. P. d. Análise de aplicação de visão computacional e redes neurais, em conjunto com o uso de técnicas de aumento de dados, na tradução automática de libras. 2023.